머신 러닝 핵심 알고리즘

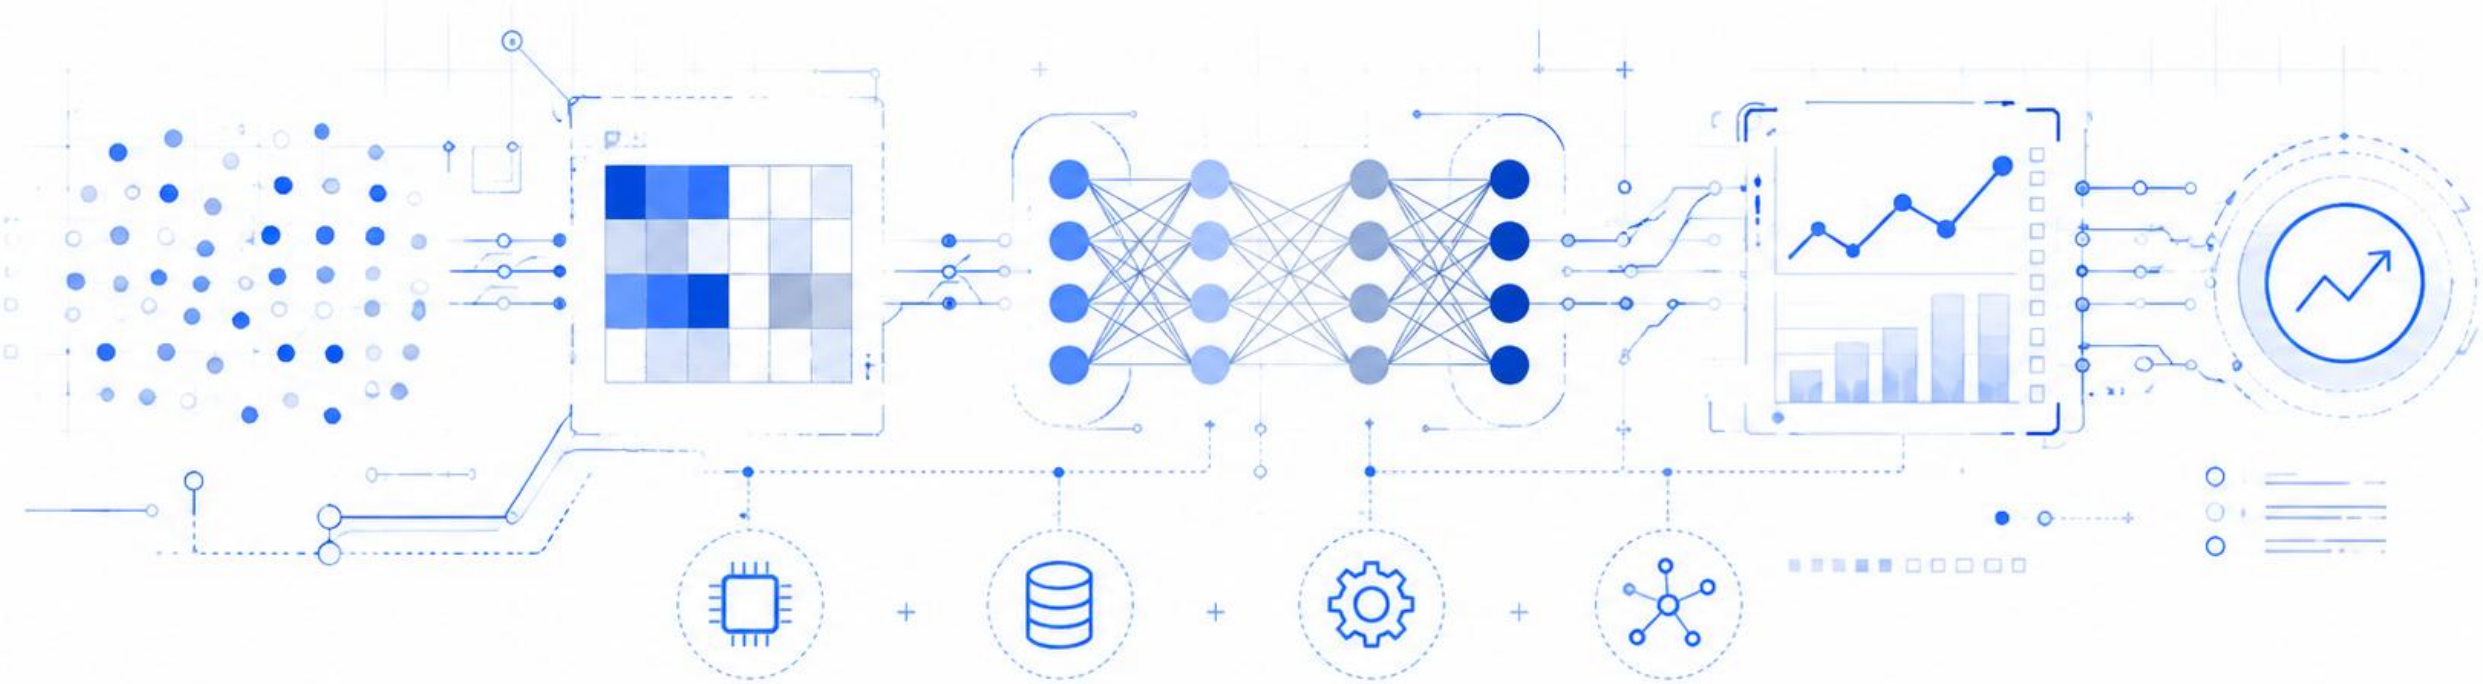
3장 스터디 발표



발표자 : 정승한
(지도교수: 양선웅)

한양대학교 ERICA 기계공학과

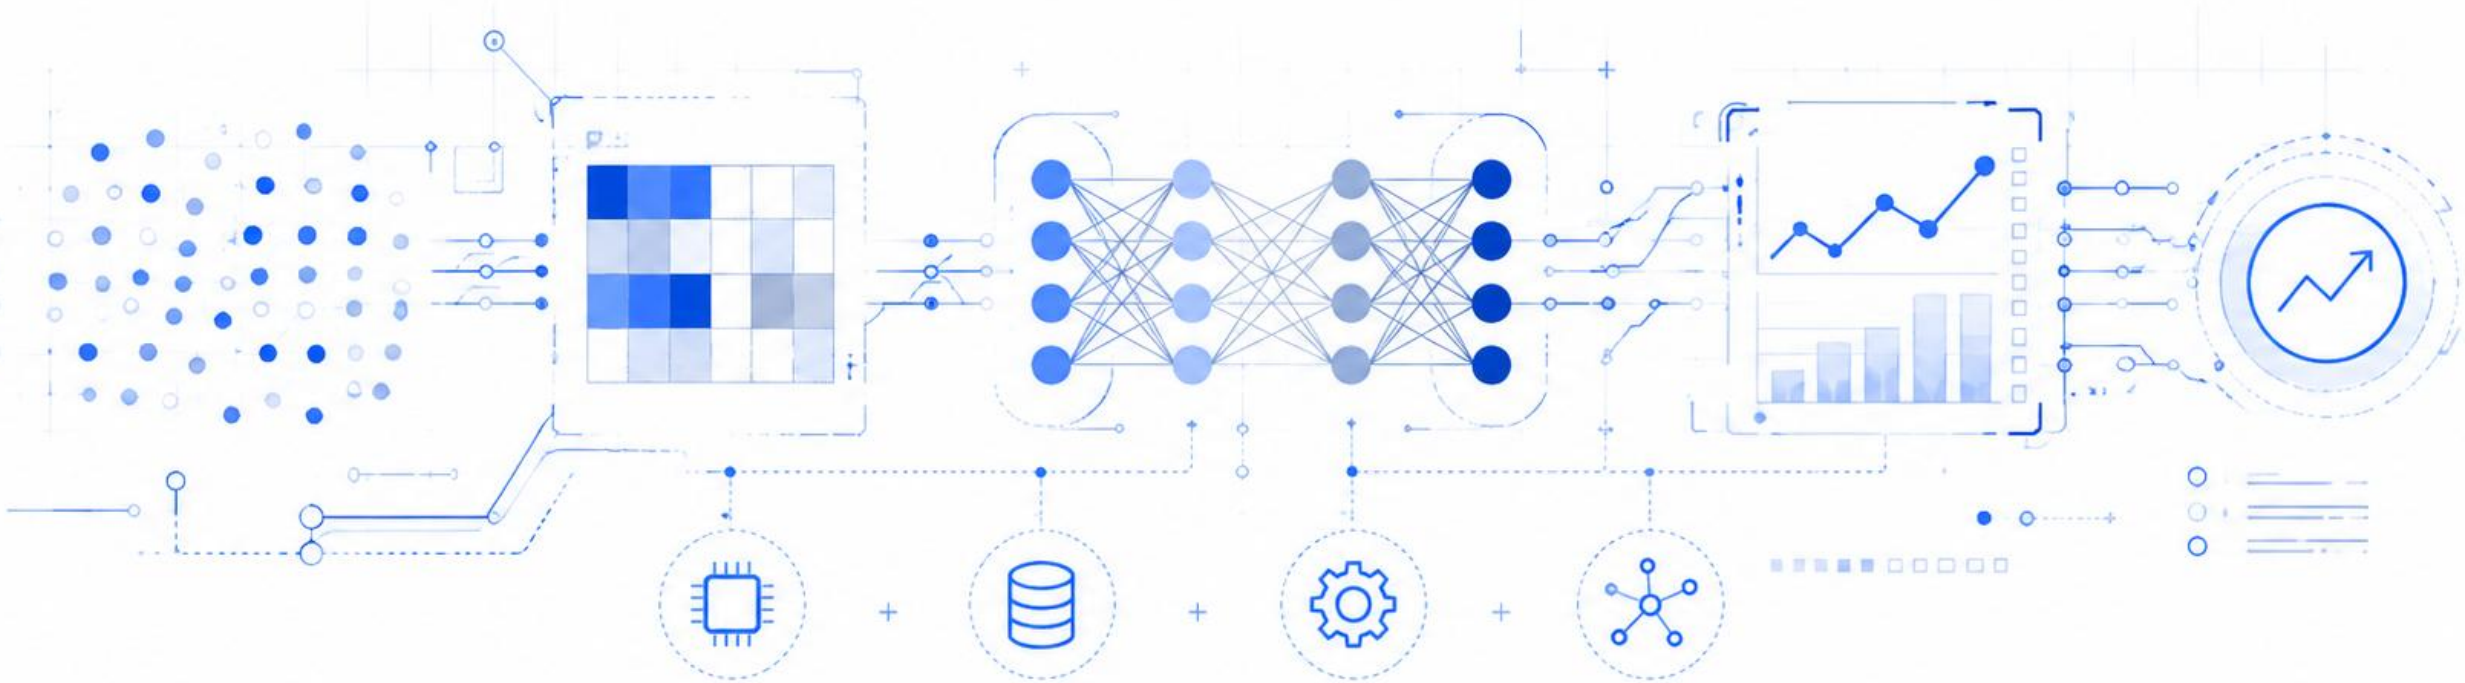
Intelligent Design for Engineering Applications Lab



지도학습 비지도 학습 결론

3장 : 머신 러닝 핵심 알고리즘

: 핵심 알고리즘에 대한 소개



지도학습 | 비지도 학습 | 결론

1. 지도 학습

: 지도 학습 알고리즘 소개

3.1 지도학습 (Supervised Learning)

■ 지도학습 (Supervised Learning)

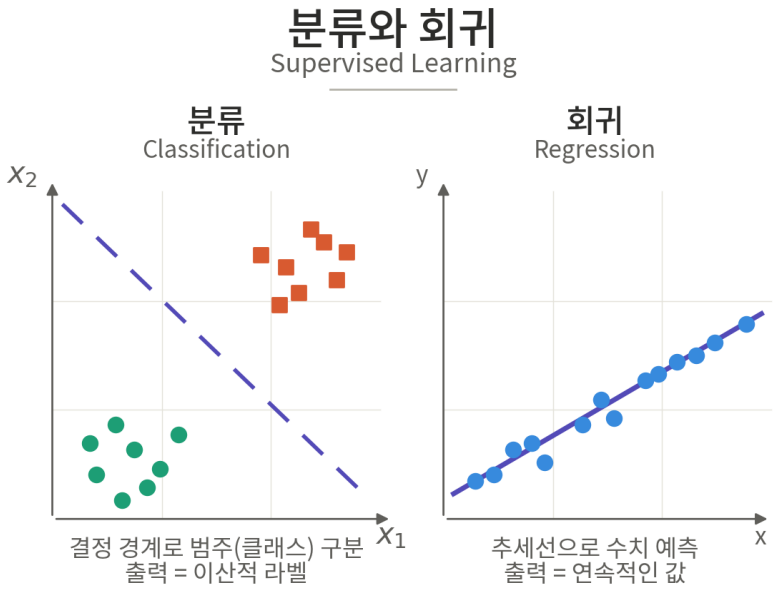
- 정답이 있는 데이터를 이용해서 모델을 학습시키는 방법
- 입력에 정답이 존재하는 데이터일때 사용

■ 분류 (Classification)

- 분류는 결과가 정해진 종류, 클래스로 나오는 문제
- 예시로는 이미지 예측, 손 글씨 이미지 분류 등이 존재함
- 결과는 이진법 0,1로 라벨링됨

■ 회귀 (Regression)

- 결과가 연속적인 숫자 값으로 나오는 문제일때 사용됨
- 예시로는 불량률, 점수 등이 존재함



➢ 분류와 회귀

Intelligent Design for Engineering Applications Lab

3.1.1 K-최근접 이웃

■ KNN, K-Nearest Neighbors

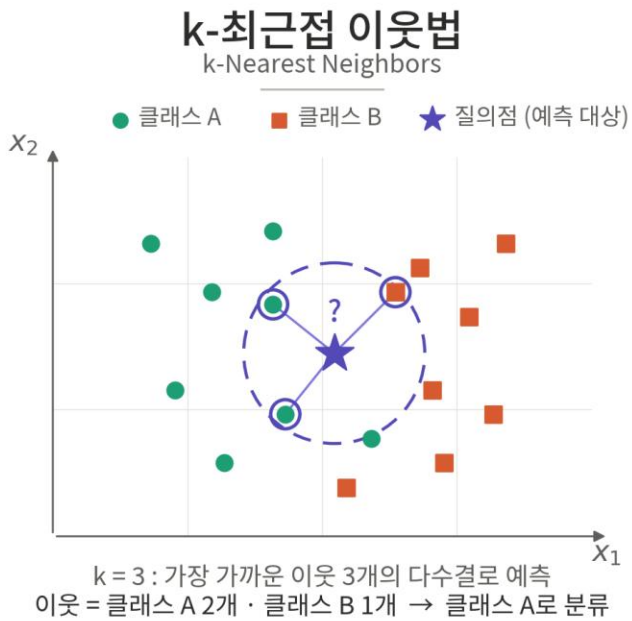
- 새로운 데이터가 들어왔을 때, 주변에 있는 가장 가까운 데이터 K개를 보고 결과 결정
- K=5일 때 가까운 데이터 5개의 훈련 샘플을 찾고 샘플의 라벨을 이용해 예측

■ K 값이란?

- K 값은 몇 개의 이웃을 참고할 것인가를 의미
- K 값이 너무 작으면 노이즈나 이상치에 약함
- K 값이 너무 크면 너무 많은 데이터를 참고해 세부적인 경계가 흐려지고 Underfitting 발생가능

■ 사이킷 런 (scikit-learn, sklearn)

- 머신 러닝 라이브러리
- KNN, SVM, 결정 트리, 로지스틱 회귀, 선형회귀와 같은 알고리즘이 담겨있음



➢ K-최근접 이웃

Intelligent Design for Engineering Applications Lab

3.1.1 K-최근접 이웃

■ 사이킷 런 코드

```
import pandas as pd
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score
from sklearn.preprocessing import StandardScaler

iris = load_iris()

dataset = pd.DataFrame(iris.data)
dataset[4] = iris.target

X = dataset.iloc[:, :-1].values
y = dataset.iloc[:, 4].values

X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.2,
    random_state=42,
    stratify=y
)

scaler = StandardScaler()
```

Pandas 라이브러리 불러오기
내장된 iris 데이터셋 불러오기
훈련과 테스트 데이터 나누기
KNN 분류모델 불러오기
정확도 점수 불러오기

사이킷 런에 있는 데이터를 iris 변수에 저장
Iris 데이터의 입력 값을 DataFrame 형태로 변환
정답 데이터를 dataset의 4번 컬럼에 추가
X 값은 입력이므로 4번(마지막열)을 제외함
Y 값은 정답이므로 4번 열만 선택함

X,y 데이터를 넣는 부분 생성
20%를 테스트로 사용
세 가지 데이터를 동일한 비율
평균 0, 표준편차 1로 스케일링

```
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)

knn = KNeighborsClassifier(n_neighbors=5)

knn.fit(X_train, y_train)

y_pred = knn.predict(X_test)

print("정확도:", accuracy_score(y_test, y_pred))
```

Fit : 훈련 데이터의 평균, 표준편차 계산
Transform : 계산한 평균과 표준편차를 데이터로 변환
Knn : KNN 모델 생성
Knn.fit : KNN 모델 훈련
Predict : 테스트 데이터로 예측 진행

■ K 값이 변할 때

- For 문 이용하여 K 값 순환
- 최적의 K 값과 정확도 찾기

Intelligent Design for Engineering Applications Lab

3.1.2 서포트 벡터 머신 (Support Vector Machine, SVM)

■ **서포트 벡터 머신**

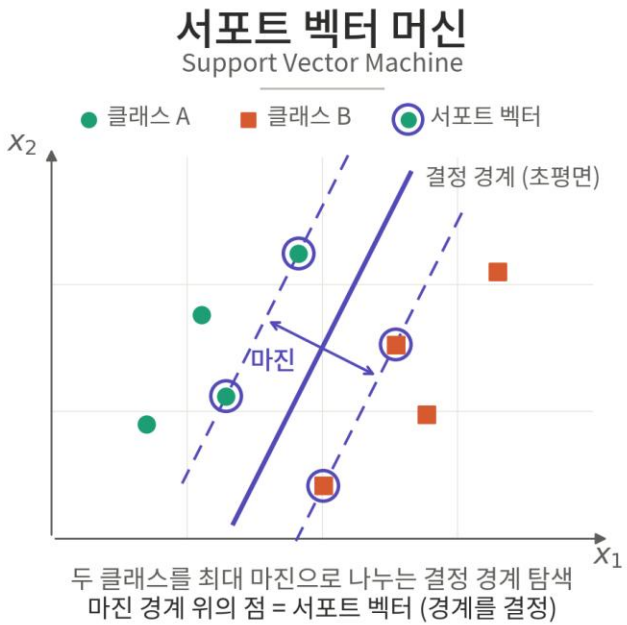
- 분류를 위한 기준선을 정의하는 모델
- 클래스를 가장 안정적으로 나누는 결정 경계를 찾음

■ **서포트 벡터**

- 결정 경계에 가장 가까이 있는 데이터를 말함
- SVM은 경계 근처에 있는 데이터가 중요

■ **마진 (Margin)**

- 서포트 벡터와 결정 경계 사이의 거리
- SVM은 데이터를 분리함과 동시에 마진 크기 최대화
- 이상치 허용에 따라 소프트 마진과 하드 마진으로 분류 가능



➢ 서포트 벡터 머신

Intelligent Design for Engineering Applications Lab

3.1.2 서포트 벡터 머신 (Support Vector Machine, SVM)

■ SVM 분류에서 선형 분류와 비선형 분류

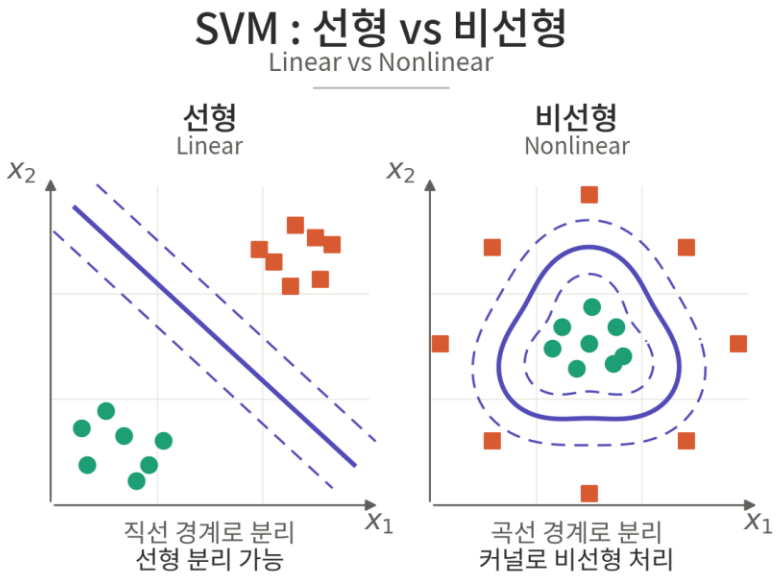
- 비선형에 대한 커널이 존재
- 커널은 선형으로 분류될 수 없는 데이터로 인해 발생

■ 커널 트릭 (Kernel trick)

- 선형 커널, 다항식 커널, 가우시안 RBF 커널이 있음

■ 선형 커널 (Linear kernel)

- 두 데이터의 내적을 이용
- $\mathrm{K}(\mathrm{a},\mathrm{b}) = a^T \cdot b$
- 기본 커널 트릭이며 커널 트릭을 사용하지 않는다는 의미를 가짐



➢ 선형 분류와 비선형 분류

Intelligent Design for Engineering Applications Lab

3.1.2 서포트 벡터 머신 (Support Vector Machine, SVM)

■ 다항식 커널 (Polynomial kernel)

- 실제로 특성을 추가하지 않으나, 다항식 특성을 많이 추가한 효과를 냄
- $\mathrm{K(a,b)} = (a^T \cdot b\ )^d$

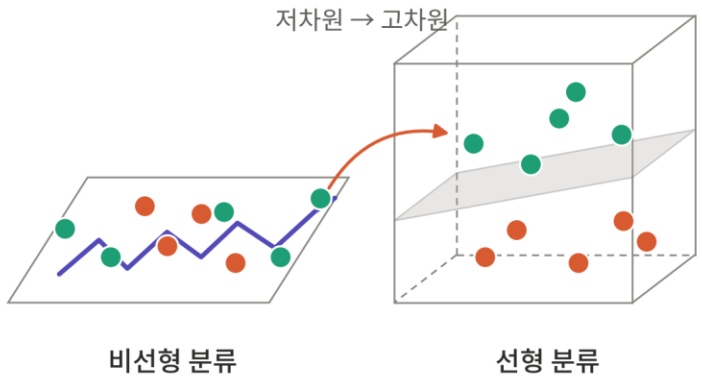
■ 가우시안 RBF 커널 (Gaussian RBF kernel)

- 다항식 커널 확장의 느낌
- 입력 벡터를 무한한 고차원으로 매핑 가능
- 다항식 커널에는 차수에 한계가 있지만, 가우시안 RBF는 차수 제한 없음
- $K(a,b) = \exp[-\gamma(a-b)^2]$

■ SVM 모델에서 하이퍼 파라미터

- C는 오류 허용 정도이며, C가 클수록 하드, 작을수록 소프트 마진
- 감마(gamma)는 결정 경계를 얼마나 유연하게 가져가는지, 즉 훈련 데이터에 얼마나 민감하게 반응하는지

커널 트릭
Kernel Trick



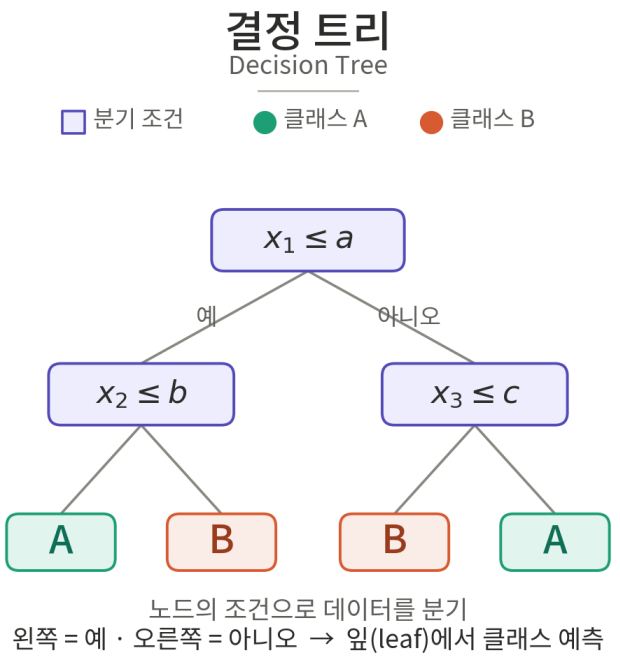
➢ 저차원 데이터 매핑

Intelligent Design for Engineering Applications Lab

3.1.3 결정 트리

■ **결정 트리**

- 데이터를 분류하거나 결과값을 예측하는 분석 방법
- 데이터를 1차로 분류한 후 각 영역의 순도와 불순도, 불확실성을 이용하여 학습
- 순도(homogeneity)는 증가, 불순도(impurity)와 불확실성(uncertainty)은 감소시키는 방향으로 학습, 이를 정보 획득(information gain)이라고 함
- 이상치가 많은 값으로 구성된 데이터 셋을 다룰 때 사용하는 것이 유리함



➢ 결정 트리

Intelligent Design for Engineering Applications Lab

3.1.3 결정 트리

■ **순도 (Purity)**

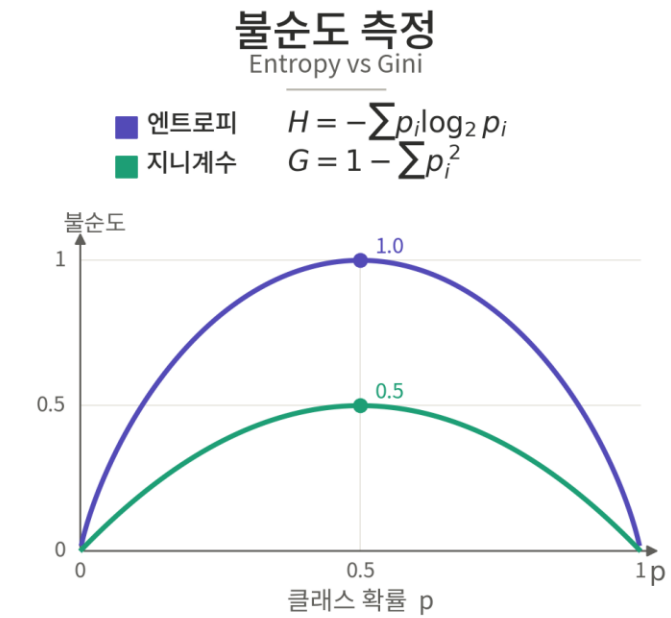
- 순도는 한 노드 안에 같은 클래스가 얼마나 잘 모여 있는지 의미

■ **불확실성 (Uncertainty)**

- 불확실성은 데이터가 얼마나 섞여 있는지를 의미

■ **엔트로피 (Entropy)**

- 불확실성을 수치로 나타내는 방법
- 성공률이 50%, 즉 반반일 때 불확실성이 가장 크고, 한쪽만 존재하는 경우 불확실성이 없음
- $Entropy(A) = -\sum_{k=1}^{m} p_k log_2(p_k)$
- $P_k = A$ 영역에 속하는 데이터 가운데 k범주에 속하는 데이터 비율 : p_k



두 지표 모두 p = 0.5에서 최대 — 클래스가 반반일 때 가장 불확실

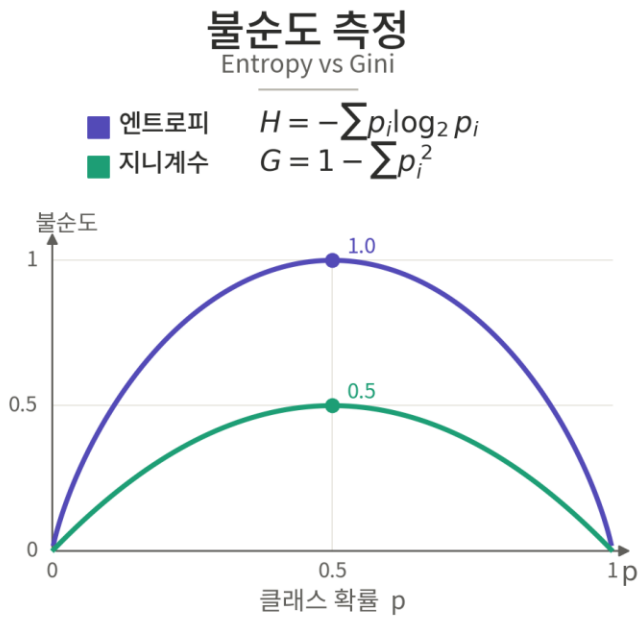
➢ 엔트로피 vs 지니 계수

Intelligent Design for Engineering Applications Lab

3.1.3 결정 트리

■ 지니 계수 (Gini index)

- 지니 불순도는 노드가 얼마나 섞여 있는지를 나타냄
- $G(s) = 1 - \sum_{i=1}^{c} p_i^2$
- S는 이미 발생한 사건의 모음, c는 사건 개수
- 지니 계수는 원소 n개 중에서 임의로 두 개를 추출했을 때, 추출된 두 개가 서로 다른 그룹에 속해 있을 확률
- 로그를 계산할 필요가 없어 엔트로피보다 계산이 빠름



두 지표 모두 p = 0.5에서 최대 — 클래스가 반반일 때 가장 불확실

➢ 엔트로피 vs 지니 계수

Intelligent Design for Engineering Applications Lab

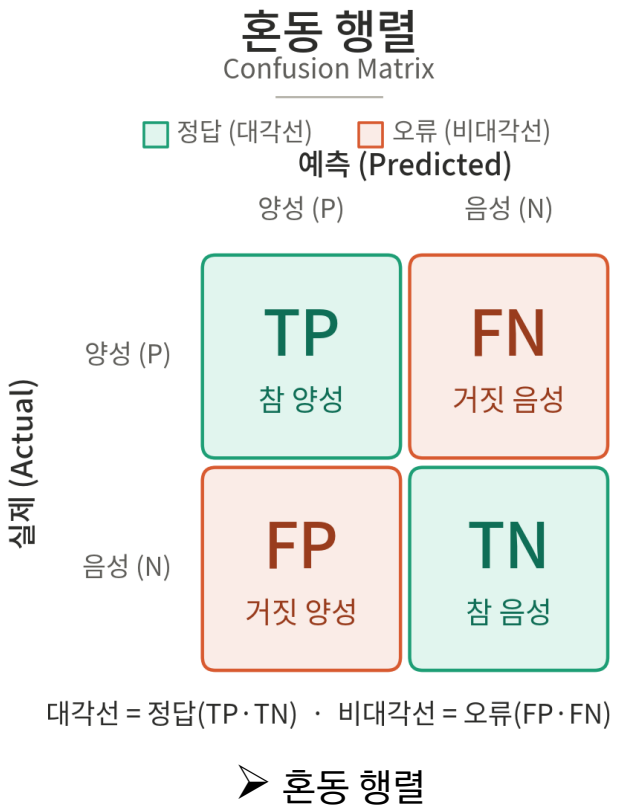
3.1.3 결정 트리

■ 혼동 행렬

- 혼동 행렬은 분류 모델이 맞춘 것과 틀린 것을 표로 정리한 것
- TP, TN, FP, FN 으로 분류함
- T는 정답, F는 오답
- P는 모델이 positive로 예측한 것
- N은 모델이 negative로 예측한 것

■ 정보 획득 (Information Gain)

- 정보 획득이란 분할 전후로 불확실성이 얼마나 줄었는지를 의미함
- 결정 트리는 여러 분할 후보 중에서 정보획득이 큰 분할을 선택



➢ 혼동 행렬

Intelligent Design for Engineering Applications Lab

3.1.4 로지스틱 회귀와 선형 회귀

■ 로지스틱 회귀

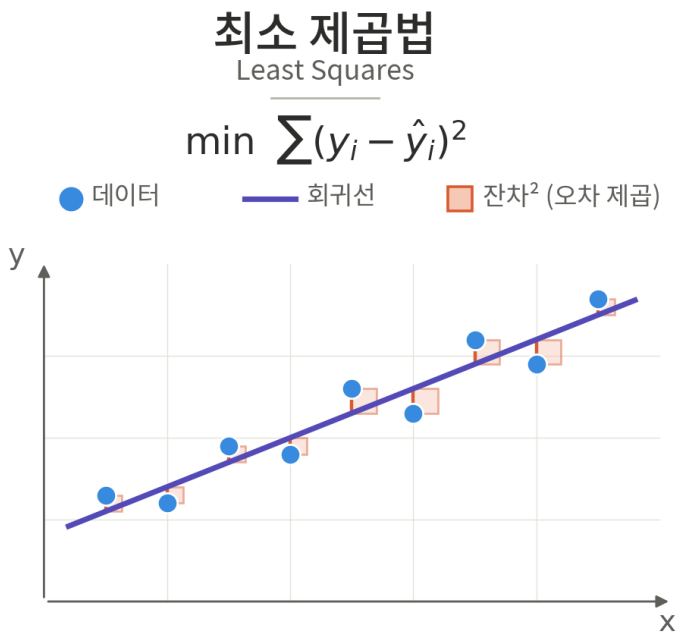
- 회귀라는 이름을 가졌지만, 주로 분류 문제에 사용됨
- 선형 회귀의 선형식을 먼저 계산한 후, sigmoid 함수를 통과시켜 확률로 변환

■ 최소제곱법 (Mean Squared)

- 선형 회귀에서 많이 사용
- $MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y_i})^2$: 평균 최소제곱법

■ 최대우도법 (Maximum likelihood estimation, MLE)

- 현재 데이터가 관측될 가능성이 가장 커지도록 모델 파라미터를 찾는 방법
- 로지스틱 회귀에서는 각 데이터가 실제 정답일 확률이 커지도록 학습
- 우도는 나타난 결과에 따라 여러 가능한 가설을 평가할 수 있는 척도
- $L(\theta) = \prod_{i=1}^{n} P(x_i|\theta)$
- 확률을 계속 곱하면 값이 너무 작아져 로그 우도 사용 : $\log L(\theta) = \sum_{i=1}^{n} logP(x_i|\theta)$



각 점과 직선의 세로 거리(잔차)의 제곱합을 최소로 만드는 직선을 찾는 방법

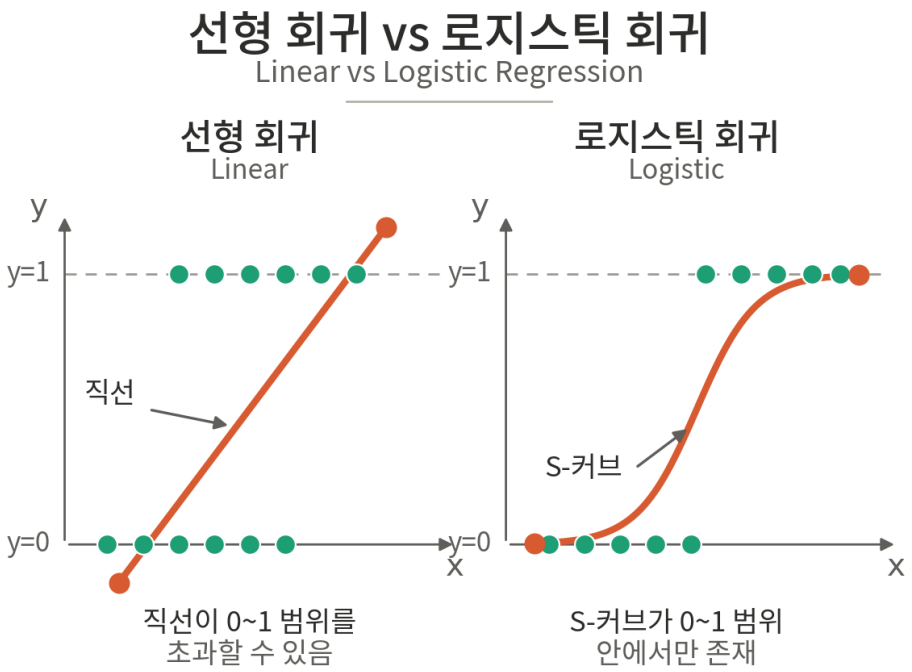
➢ 엔트로피 vs 지니 계수

Intelligent Design for Engineering Applications Lab

3.1.4 로지스틱 회귀와 선형 회귀

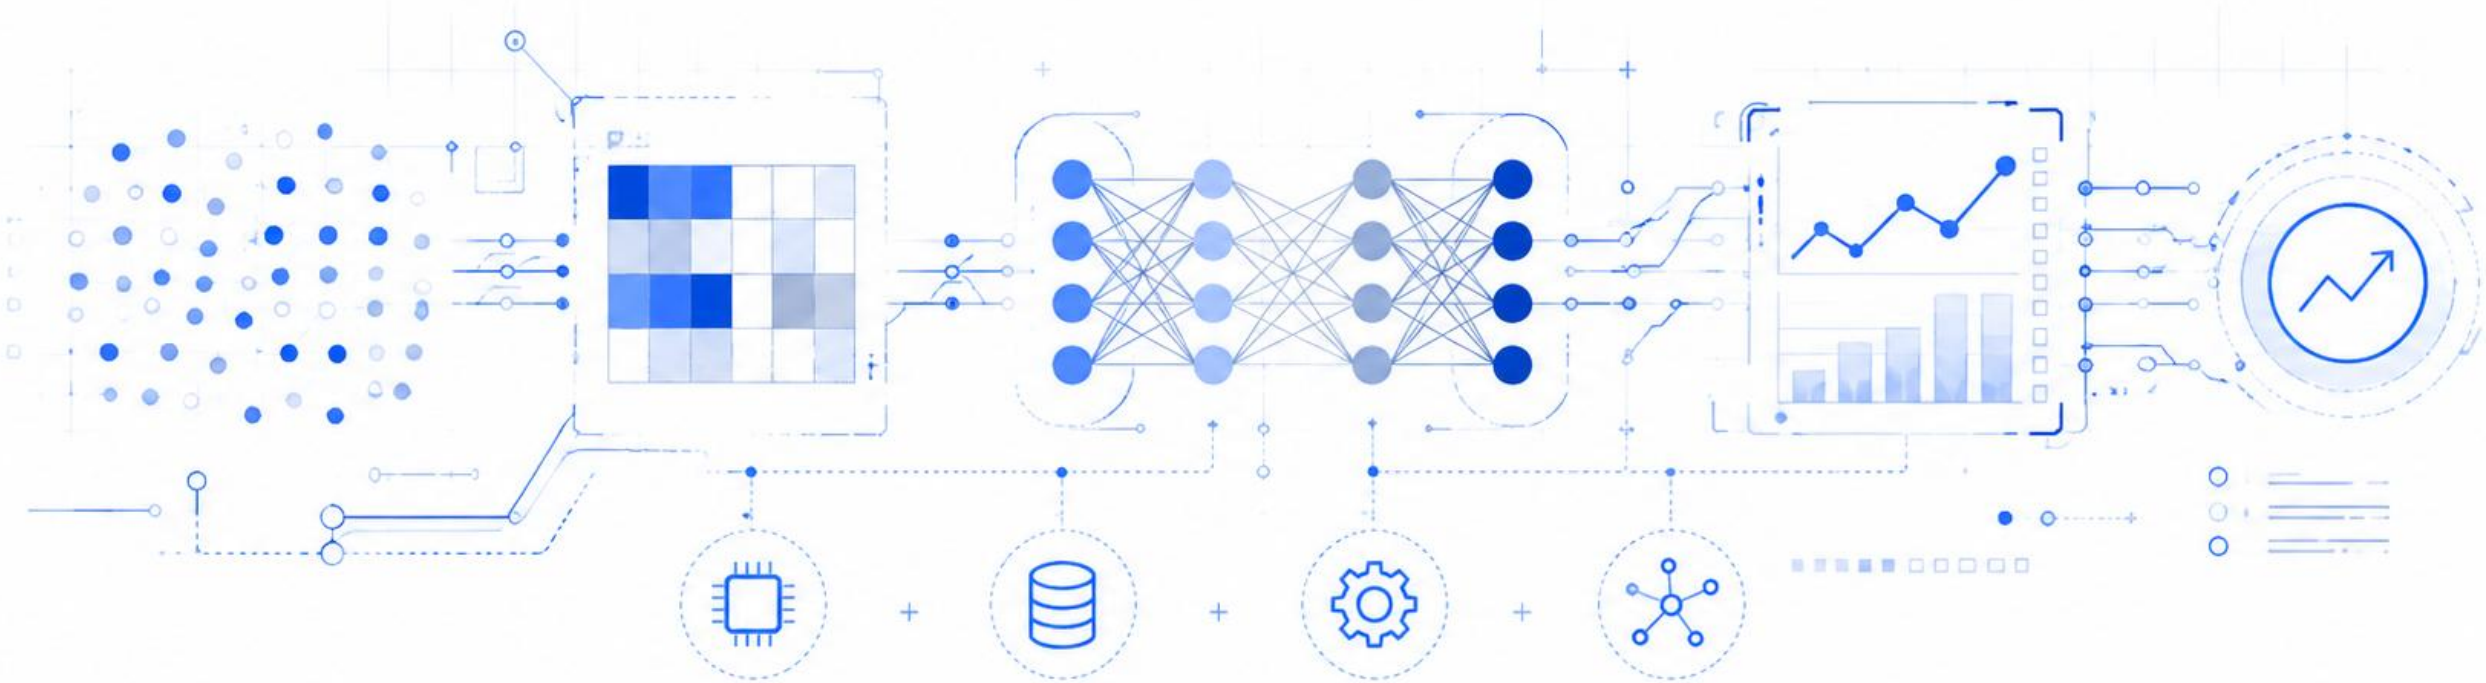
■ 선형 회귀 (Linear regression)

- 입력 변수로 결과를 예측
- 전체적인 경향이 직선처럼 보인다면 선형 회귀 사용
- 실제 값 y와 예측 값 $\hat{y}$의 차이 (오차)를 줄이는 것
- 입력 변수가 여러 개인 경우는 다중 선형 회귀
- $\hat{y} = w_1 x_1 + w_2 x_2 + w_3 x_3 + \cdots + b$
- w는 는 가중치 (coefficient), 각 입력변수가 결과에 얼마나 영향을 주는지



➢ 선형 회귀와 로지스틱 회귀 차이점

Intelligent Design for Engineering Applications Lab



지도학습 | 비지도 학습 | 결론

2. 비지도 학습

: 비지도 학습 알고리즘 소개

3.2 비지도 학습 (Unsupervised Learning)

■ 비지도 학습 (Unsupervised Learning)

- 비지도 학습은 정답 데이터인 y없이, 입력 데이터 X만 가지고 데이터 안의 패턴, 구조, 특징을 찾아내는 머신 러닝 방법
- 비지도 학습에는 군집과 차원 축소가 있음

■ 군집화 (Clustering)

- 비지도 학습의 대표적인 방법으로, 정답 없이 입력 데이터만 보고 비슷한 데이터끼리 자동으로 묶는 방법
- 군집화의 목적은 데이터 안에 숨어 있는 구조나 패턴을 찾는 것

■ 차원 축소 (Dimensionality Reduction)

- 데이터의 변수, 특성의 개수를 줄이는 방법
- 데이터의 정보를 최대한 유지하며 복잡한 데이터를 적은 변수로 줄이는 것
- 머신 러닝에서 차원은 보통 입력 특성의 개수를 의미함

Intelligent Design for Engineering Applications Lab

3.2.1 K-평균 군집화 (K-means Clustering)

■ K-평균 군집화 (K-means clustering)

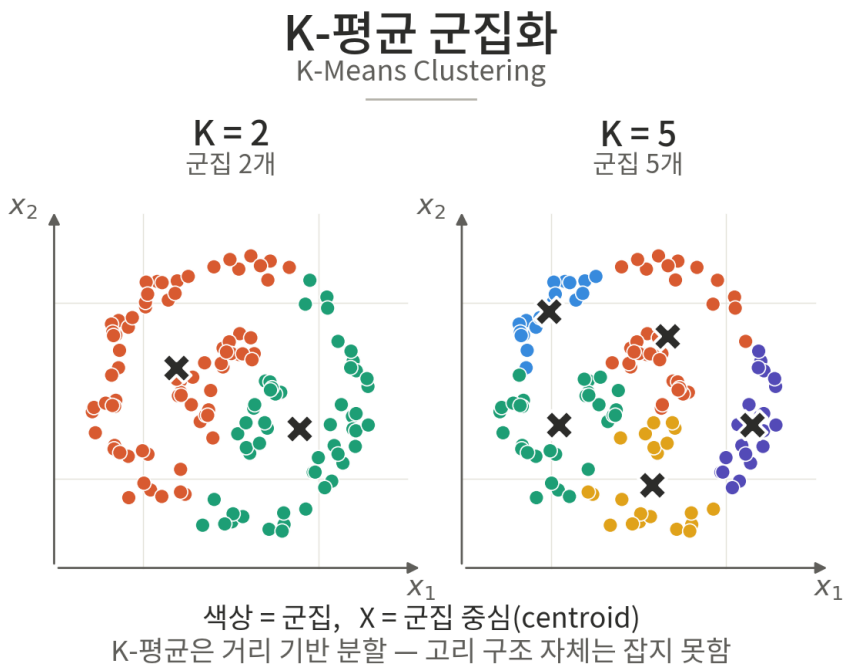
- K-평균 군집화는 비슷한 데이터끼리 K개의 그룹으로 나누는 비지도 학습
- K는 군집의 개수 = 중심점의 개수
- Cluster는 비슷한 데이터끼리 모인 그룹

■ 중심점 (Centroid)

- 중심점은 각 군집을 대표하는 평균 위치
- x값의 평균, y값의 평균이 각각 중심점이 됨

■ 거리 계산

- K-평균은 각 데이터가 어느 중심점과 가까운지를 기준으로 군집화
- $distance = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$ (유클리드 거리)



➢ K값이 다른 K-평균 군집화

Intelligent Design for Engineering Applications Lab

3.2.1 K-평균 군집화 (K-means Clustering)

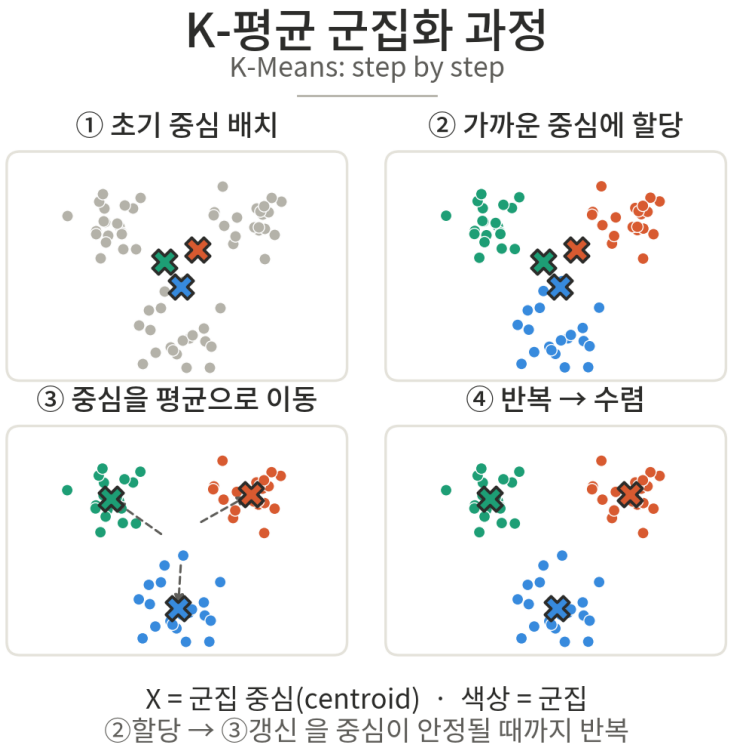
■ K-평균 군집화 과정

- K-평균은 중심점 설정, 데이터 배정, 중심점 갱신을 반복하면서 군집 생성

1. K값을 정함
2. K개의 중심점을 임의로 배치
3. 각 데이터를 가장 가까운 중심점에 배정 (클러스터 할당)
4. 각 군집의 평균 위치로 중심점을 다시 이동 (새로운 중심점 선택)
5. 데이터 배정이 더 이상 거의 변하지 않을 때까지 반복 (범위 확인 convergence)

■ K-평균 군집화 알고리즘 사용 시 주의 사항

- K-평균 군집화 알고리즘은 비선형인 경우, 군집크기가 다를 경우, 군집마다 밀집도와 거리가 다른 경우에는 데이터 분류가 원하는 결과와 다르게 발생할 수 있음



➢ K-평균 군집화 과정

Intelligent Design for Engineering Applications Lab

3.2.1 K-평균 군집화 (K-means Clustering)

■ **거리 제곱의 합** (Sum of Squared Distances, SSD)

- 거리 제곱의 합은 두 x,y 데이터의 차를 구해서 제곱한 값을 모두 더한 후
  유사성을 측정하는 데 사용
- $SSD = \sum_{x,y}(I_1(x,y) - I_2(x,y))^2$
- K값이 증가하면 거리 제곱의 합은 0에 가까워 짐
- K의 최댓값 n(샘플 수)으로 설정하면 각 샘플이 자체 클러스터를 형성하기 때문

Intelligent Design for Engineering Applications Lab

3.2.2 밀도 기반 군집 분석

■ 밀도 기반 군집 분석 (DBSCAN)

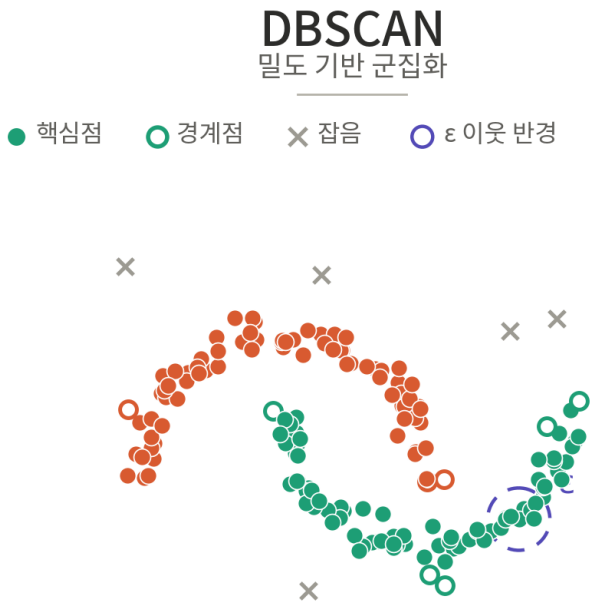
- 밀도 기반 군집 분석은 데이터가 밀도 높게 모인 영역을 군집으로 판단하는 비지도 학습 방법 (일정 밀도 이상)
- 노이즈에 영향을 받지 않으며, K-means 에 비해 연산량은 많으나 K-means가 잘 처리하지 못하는 오목, 볼록한 부분 처리하는 데 유용

■ ε 엡실론 (이웃 반경)

- eps는 한 데이터 주변을 어느 거리까지 이웃으로 볼 것인지 정하는 값

■ m (minPts, min_samples)

- minPts는 한 점 주변에 최소 몇 개의 데이터가 있어야 밀도 높은 지역으로 볼지 정하는 값
- 예를 들어 minPts = 3이라면 P1 중심점을 포함해 반경 엡실론 내에 점이 3개 이상 있으면 하나의 군집으로 판단



조밀한 영역을 군집으로, 희박한 점은 잡음(이상치)으로 분리
군집 개수를 정하지 않고 임의 모양(비선형) 군집을 찾음

➢ DBSCAN

Intelligent Design for Engineering Applications Lab

3.2.2 밀도 기반 군집 분석

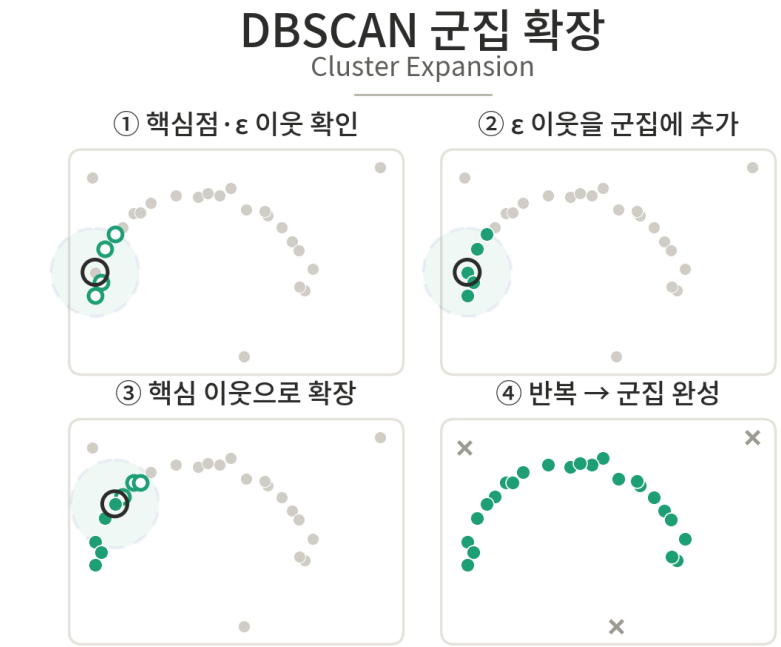
■ 밀도 기반 군집 분석 과정

- DBSCAN은 중심점을 찾고 주변의 밀집된 점들을 연결하며 군집 확장

1. 임의의 데이터 하나 선택
2. eps 거리 내의 이웃 데이터 탐색
3. 이웃 수가 minPts 이상이면 중심점으로 판단
4. 중심점 주변의 데이터들을 동일 군집으로 포괄
5. 연결된 중심점을 따라 군집 확장

■ DBSCAN의 점 종류

- Core point (중심점) : 주변에 minPts 이상 데이터가 존재하는 점
- Border point (경계점) : 중심점 근처에 존재하나 자신의 밀도는 낮은 점
- Noise point (노이즈점) : 어떤 군집에도 속하지 않은 이상치 데이터 점



ε 안에 이웃이 많은 핵심점에서 시작 → 이웃→이웃으로 밀도가 이어지는 한 확장
더 뗌어나가지 못하면 군집 종료 · 닿지 않은 점은 잡음(noise)

➢ DBSCAN의 과정

Intelligent Design for Engineering Applications Lab

3.2.2 밀도 기반 군집 분석

■ 밀도 기반 군집의 장점

- K값 불필요
- 이상치 탐지 가능 (노이즈 데이터 분리)
- 복잡한 군집 형성 가능
- 직관적 군집 형성 (가까이 모인 점들을 군집으로)

■ 밀도 기반 군집의 단점

- eps가 너무 작으면 노이즈 점이 많아짐
- eps가 너무 크면 달라야 하는 군집이 하나로 합쳐짐
- 밀도가 다른 군집이 존재하는 경우 성능 하락 가능

K-평균 vs DBSCAN

군집화 비교

K-평균 = 중심점 기준 · DBSCAN = 밀도 기준

구분	K-평균 군집화	DBSCAN
기준	중심점과의 거리	데이터 밀도
군집 개수	K를 직접 정해야 함	자동으로 찾음
군집 모양	둥근 형태에 유리	복잡한 모양도 가능
이상치 처리	약함	강함
주요 파라미터	K	eps, min_samples
결과	모든 데이터가 군집에 포함됨	일부 데이터는 노이즈 가능

➢ DBSCAN과 K-평균 군집화의 차이점

Intelligent Design for Engineering Applications Lab

3.2.3 주성분 분석 (Principal Component Analysis, PCA)

■ 주성분 분석 (PCA)

- PCA 주성분 분석은 데이터의 특성이 많을 경우, 중요한 정보는 유지하며 차원을 줄이는 대표적인 차원축소 방법
- PCA는 데이터가 가장 많이 퍼져 있는 방향을 찾아 새로운 축을 형성

■ 주성분의 의미

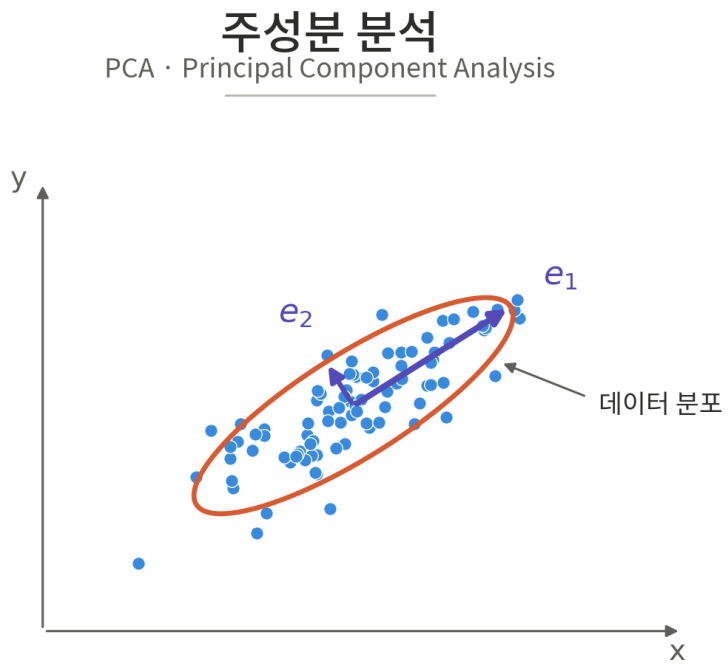
- 주성분은 원래 변수들을 조합해서 만든 새로운 축

■ PCA 사용 이유

- PCA는 데이터의 정보 손실을 최소화하며 특성 개수를 줄이기 위해 사용
- 시각화, 계산량 감소, 노이즈 제거, 과적합 완화, 데이터 압축 등의 특징이 있음

■ PCA의 기준 : 분산

- PCA는 분산이 큰 방향을 중요한 정보가 많은 방향으로 인식



분산이 가장 큰 방향이 첫 주성분 e1, 수직 방향이 e2
데이터를 가장 잘 설명하는 새 축(주성분)을 찾음

➢ PCA의 데이터 선택 (e_1, e_2)

Intelligent Design for Engineering Applications Lab

3.2.3 주성분 분석 (Principal Component Analysis, PCA)

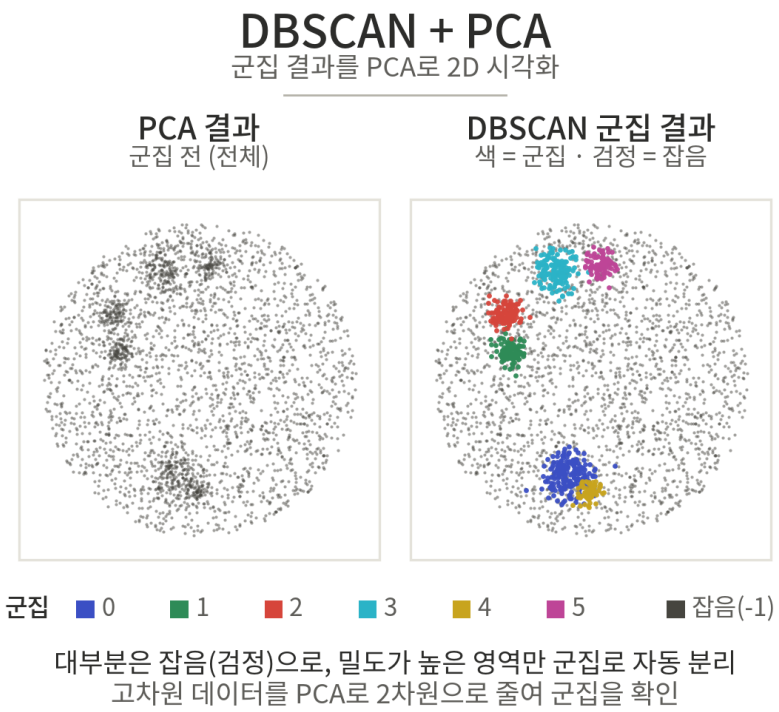
■ 주성분 분석 과정

- 여러 데이터가 모여 하나의 분포를 이룰 때 분포의 주성분을 분석

1. 데이터 특성 스케일링
2. 데이터 분산 계산
3. 분산이 가장 큰 방향 탐색
4. 원하는 개수의 주성분 선택
5. 데이터를 새로운 주성분 축으로 변환

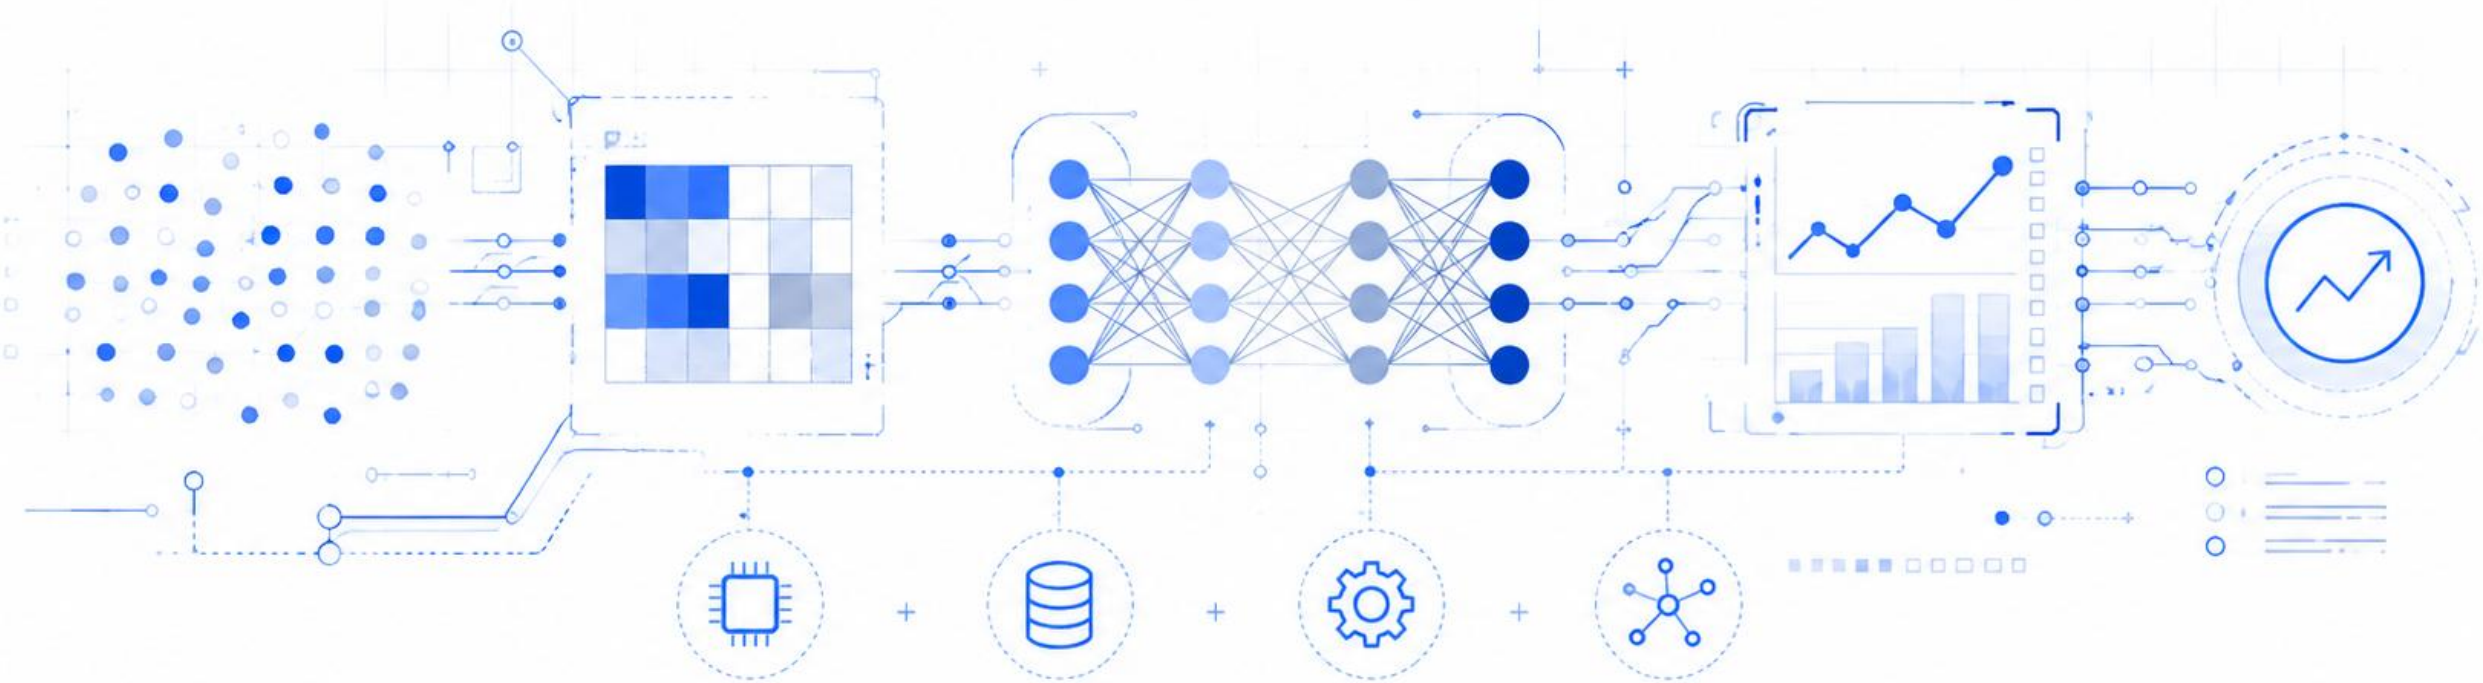
■ PCA 알고리즘 사용 시 주의 사항

- PCA는 분산을 기준으로 보기에 변수의 단위가 다르면 결과가 왜곡되므로 스케일링이 필요



➢ PCA로 2차원 시각화 후 DBSCAN로 군집 형성

Intelligent Design for Engineering Applications Lab



지도학습 | 비지도 학습 | 결론

3. 결론

: 각 알고리즘 사용 상황과 장단점 정리

3.3 결론 : 지도 학습

알고리즘	사용하면 좋은 환경	장점	단점
KNN	데이터 적고 저차원일 때	단순함, 비선형 경계 가능	데이터 많으면 느림, 고차원에 약함
SVM	고차원, 명확히 나뉘는 분류	고차원에 강력, 커널로 비선형	대용량에 느림, 튜닝 필요
결정 트리	해석 중요, 이상치 많을 때	해석 쉬움, 스케일링 불필요	과적합 쉬움, 불안정함
선형 회귀	연속값, 선형 관계일 때	단순·빠름, 변수 영향 해석	선형만 가능, 이상치에 민감
로지스틱 회귀	이진 분류, 확률이 필요할 때	확률 출력, 해석 쉬움	복잡한 비선형에 약함

Intelligent Design for Engineering Applications Lab

3.3 결론 : 비지도 학습

알고리즘	사용하면 좋은 환경	장점	단점
K-평균 군집화	군집 수를 알 때, 둥근 군집	빠름, 대용량에 강함	K 직접 지정, 모양 제한적
DBSCAN	군집 수 모름, 복잡한 모양	K 불필요, 이상치 탐지	eps에 민감, 밀도차에 약함
PCA	특성 많음, 시각화·전처리	차원 축소, 노이즈 제거	축 해석 어려움, 스케일링 필수

Intelligent Design for Engineering Applications Lab

3.3 결론 : 요약

- 해석이 중요한 경우 : 결정 트리 / 로지스틱 회귀 / 선형 회귀
- 고차원 정확도가 중요한 경우 : SVM
- 군집 개수를 모르는 경우, 군집 형태가 복잡 : DBSCAN
- 단순한 군집화 : K-평균 군집화
- 특성이 너무 많은 경우 : PCA 축소 이후 다른 알고리즘 적용

Intelligent Design for Engineering Applications Lab

Any Questions?

이름 정 승 한

소속 한양대학교 기계공학과

이메일 jshan0407@hanyang.ac.kr

IDEA Intelligent Design for Engineering Applications Lab



